

周明

技术负责人 · 后端与分布式平台 · AI Agent 系统

上海 | zcm_5237@163.com | +86 159-2173-1253 | 中英双语

个人简介

后端和平台工程师，12+ 年金融服务与大规模互联网经验（花旗、eBay）。过去六年在花旗担任技术负责人，基于 LangGraph、LlamaIndex 和 Milvus 构建并运营生产级 AI Agent 平台。平台服务于多区域受监管环境下的多条业务线 workflow，在可靠性、可追溯性和数据隔离方面有硬性要求。

亲手参与架构、编码和运维。在分布式系统、API 设计、SLO/SLI、可观测性以及通过金丝雀发布和回滚实现安全交付方面有扎实功底。与产品紧密合作决定做什么，指导高级工程师，在全球分布式团队中高效协作。中英双语流利。

核心项目（花旗，2019 – 2025）

AI Agent 平台 — 可治理的 RAG 与 Agentic 工作流

LangGraph 编排 · 可审计 RAG · 工具调用 · 结构化输出 · 人在环路 · SRE 级可靠性

主导端到端 AI Agent 平台的设计、交付和生产运营。将依赖专家的手动工作流转变为自助式、可重放、风险可控的人机协作系统，适用于受监管的多区域场景。

- 从 0 到 1 构建平台。将编排、检索、策略门控和审计日志标准化为共享基础设施。扩展至 3—8 条业务线和 6—12 个领域；接入 20K—50K 受治理制品和 100—300+ 模板。
- 将引用和结构化输出定为平台契约（“无证据，无结论”）。引用覆盖率保持 95—99%；因不可验证引用导致的下游驳回从约 12—18% 降至约 6—10%。
- 针对 LLM 不确定性设计确定性安全控制：可回答性 + 风险路由（回答 / 拒绝 / 仅引用 / 升级）。升级率保持 5—15%；无依据或不匹配回答从约 2—4% 降至约 1—2%。
- 将版本、管辖区和权限作为检索和引用的一等约束。错版本或未授权引用从 15—25 次/月降至 3—8 次/月。
- 按 SRE 标准生产化：SLO、分布式追踪、审计日志、金丝雀发布 + 回滚、运维手册。P1/P2 事故 6—10 → 3—6 次/月；MTTR 60—90 分钟 → 25—45 分钟；宕机影响降低约 40%。
- 建立受治理的模型生命周期：基于重放的评估、回归门控、升级/回滚。轻量级对齐（7B QLoRA，脱敏数据）将结构化格式错误从约 12—20% 降至约 4—8%。

技术栈：Python, FastAPI, LangGraph, LlamaIndex + Milvus, Redis, OpenTelemetry, Jaeger, Langfuse, vLLM, LMDeploy, Prometheus / Grafana, Kubernetes, Helm, Istio, XTuner (QLoRA)。

工作流自动化 Agent — 跨内部系统的计划执行引擎

工具调用 · 最小权限检索 · 结构化证据包 · 端到端可追溯

负责交付一个跨 10—20 个内部系统和 API 自动化多步骤工作流的 Agent。标准化了可控、可重放、审计就绪的管道，缩短了周期时间、减少了返工和跨系统数据暴露。

- 构建可复用的计划执行工作流引擎。多步骤任务变为受治理的、可重放的管道，运行在最小权限约束下。
- 设计带执行控制的连接层（白名单、步骤预算、重试/超时、熔断器、分级降级）。平均步骤数 18—25 → 10—16；p95 运行时间 25—40 分钟 → 12—25 分钟。
- 集成 10—20 个内部系统和 API（工单、审批、访问/变更日志、报告、告警、配置快照）。"错误周期/版本/未找到"返工从 40—70 次/月降至 20—45 次/月。
- 通过验证门控实现质量左移（时间窗口、所有者、审批链、权威来源、冲突检测）。下游驳回率 18—28% → 10—18%。
- 标准化输出包 schema，遵循最小披露原则（ID、字段、时间戳、哈希）。手动脱敏负载 10—16% → 5—10%。
- 扩展至 200—500 活跃用户和 3K—10K 次/月执行。通过全链路追溯，根因定位时间 2—4 小时 → 0.5—1.5 小时。

技术栈：Python, FastAPI, LangGraph, 内部 HTTP/gRPC APIs, OpenTelemetry, Jaeger, Langfuse, Prometheus / Grafana, Kubernetes, Helm, Istio。

决策支持 Agent — Maker-Checker 与人在环路

基于角色的协作 (Planner / Executor / Critic) · Maker-Checker · 决策仲裁 · 可审计重放

构建面向高风险决策点的决策支持 Agent。将基于经验的分散审批转化为标准化的 maker-checker 工作流，明确人员责任。

- 构建 maker-checker 决策工作流框架，实现"无签核、无签发"和可审计追踪。
- 编码可执行的审查标准和仲裁规则（批准 / 返工 / 升级），处理证据缺失或冲突以及权限/管辖区阻断。中位重审轮次 2 → 1。
- 将高风险人工签核覆盖率从约 70—80% 提升至约 95—99%，通过自动化二线检查和分级审批。
- 标准化结构化审查包。跨团队争议/差异从 15—25% 降至 5—10%。
- 至可审查输出的周期时间：p50 2—4 小时 → 45—90 分钟；p95 1—2 个工作日 → 4—8 小时。
- 运维化重放和治理：trace_id、角色链、规则命中、证据 ID、仲裁结果、审批——回馈至重放/回归测试套件。

技术栈：Python, FastAPI, LangGraph, OpenTelemetry, Jaeger, Langfuse, Prometheus / Grafana, Kubernetes, Helm, Istio。

工作经历

花旗，上海 — 助理副总裁 / 技术负责人

2019.07 — 2025.09

- 主导 AI Agent / RAG 平台的架构和交付，服务于受监管、审计敏感的工作流。将 LangGraph / LlamaIndex / Milvus 与确定性门控、可解释性追踪和受控升级路径结合。
- 负责平台可靠性和发布治理：SLO/SLI、告警和运维手册、通过 Istio 的金丝雀发布、CI/CD 加固和安全扫描。
- 制定 RFC、设计评审和事后复盘的工程标准。指导高级工程师，与产品合作确定方案方向。

eBay (AWF), 上海 — 高级全栈工程师

2018.10 — 2019.07

- 构建并运营面向大规模遥测数据的实时日志分析和告警平台。主导 MySQL → TiDB 迁移和基于 Kubernetes 的部署以提升可扩展性。
- 在大规模电商环境中加强生产可观测性 (Prometheus / Grafana) 和事件响应流程。

你我贷, 上海 — 高级全栈工程师

2018.07 — 2018.10

- 交付借贷工作流系统的后端服务。专注于吞吐量/延迟调优和生产加固 (超时/重试、幂等性、运维就绪)。

花旗, 上海 — 高级全栈工程师

2016.08 — 2018.07

- 基于 Spring Boot / Spring Cloud 设计和交付内部财务和运营平台的分布式服务。专注于 API 架构、数据集成和可靠性基础 (监控、运维手册、值班)。

早期经历 — 全栈 / 高级工程师

2012.12 — 2016.06

ODianYun、纬创、北京沐融科技。构建企业应用和后端服务；建立系统设计、数据存储、部署和生产支持的基础。

教育背景

华东交通大学 计算机科学与技术 学士

2009 — 2013

技术技能

语言：Java, Python。熟悉 TypeScript / Node.js。

LLM / AI 工程：LangGraph, LangChain, LlamaIndex, Milvus, 混合检索 (向量 + BM25), 重排序, 元数据版本管理, 工具/函数调用, 结构化输出, 评估与重放, 安全护栏 (PII 最小化、提示注入防御), OpenAI API, Hugging Face (Transformers, LoRA / QLoRA), InternLM XTuner, vLLM, LMDeploy (Turbomind / PyTorch / TensorRT-LLM)。

后端与 API：Spring Boot, Spring Cloud, FastAPI, Flask, Gunicorn, RESTful 微服务, API 设计与集成, 事件驱动架构。

分布式系统与可靠性：高可用, 低延迟, SLO / SLI, 告警和运维手册, 事故调试, 金丝雀发布, 流量管理, 超时/重试/熔断器, 幂等性。

数据库与缓存：MySQL, PostgreSQL, TiDB, MongoDB, Redis。

云原生与 DevOps：Docker, Kubernetes, Helm, Istio, Jenkins, GitHub Actions, 加固镜像, 带自动化测试和安全扫描的 CI/CD。

可观测性： Prometheus, Grafana, OpenTelemetry (Collector), Jaeger, Langfuse。

开发工具： Claude Code, Cursor, GitHub Copilot, n8n。日常用于编码、代码评审、测试、文档和工程效能。